


Этап 2. Обоснование выбора размера индекса B

При $B = 10$ ($m=1024$) ошибка составляет $\approx 3.25\%$, что является достаточно высоким показателем для точных измерений.

При $B = 12$ ($m=4096$) ошибка снижается до $\approx 1.625\%$.

Дальнейшее увеличение B до 14 или 16 требует кратного увеличения памяти (16 КБ и 64 КБ соответственно) при относительно незначительном приросте точности (до 0.8% и 0.4%).



Этап 3. Анализ результатов работы алгоритма HyperLogLog

1. Оценка точности алгоритма и сравнение с теоретическими пределами

В рамках эксперимента использовался размер индекса $B = 12$, что соответствует количеству регистров $m = 2^{12} = 4096$. Для оценки точности необходимо сравнить полученные экспериментальные отклонения с теоретическими границами, заданными формулами:

1. Стандартная ошибка (Standard Error): $SE_{std} = \frac{1.04}{\sqrt{2^B}} = \frac{1.04}{\sqrt{4096}} = \frac{1.04}{64} \approx 0.01625 \ (1.63\%)$
2. Консервативная оценка отклонения: $SE_{cons} = \frac{1.30}{\sqrt{2^B}} = \frac{1.30}{\sqrt{4096}} = \frac{1.30}{64} \approx 0.02031 \ (2.03\%)$

Анализ Графика №1 показывает, что отклонение оценки N_t от истинного значения F_0 на всем протяжении потока (100 000 элементов) минимально. Визуальный анализ и данные Графика №2 (доверительный интервал) подтверждают, что среднеквадратичное отклонение экспериментальных данных находится в пределах 1.6% .

Вывод: Реализованный алгоритм демонстрирует точность, соответствующую более строгому теоретическому пределу $\frac{1.04}{\sqrt{m}}$. Экспериментальная погрешность не превышает значения 1.63% , что значительно ниже консервативной границы в 2.03% . Это говорит о корректной реализации логики распределения по регистрам и высоком качестве используемой хеш-функции MurmurHash3.

2. Анализ стабильности и дисперсии

График №2 демонстрирует зависимость дисперсии оценки от объема обработанных данных.

- Доверительный интервал: Закрашенная область $\mathbb{E}(N_t) \pm \sigma_{N_t}$ остается узкой на всем диапазоне значений. Ширина интервала растет линейно с увеличением кардинальности множества, что означает постоянство относительной ошибки.
- Центрирование: Линия истинного значения проходит через центр области неопределенности, что указывает на несмещенность оценки.

Высокая кучность результатов запусков вокруг математического ожидания подтверждает стабильность алгоритма.

3. Эффективность выбранных констант

1. Коэффициент α_m : Мы использовали значение $\alpha_m \approx 0.721$. Поскольку на графиках оценка совпадает с реальным количеством элементов, это доказывает, что коэффициент подобран верно. Он сработал как калибровка, убрав постоянную погрешность формулы.
2. **Linear Counting** (Коррекция для малых чисел): В самом начале графика (где элементов меньше 10 000) линия идет ровно и гладко, без скачков. Это подтверждает, что алгоритм правильно переключается на специальный режим подсчета для малых данных. Благодаря этому точность остается высокой в начале работы, когда обычная формула могла ошибиться.